Scrapy爬虫基本使用

WS11

嵩天

www.python123.org

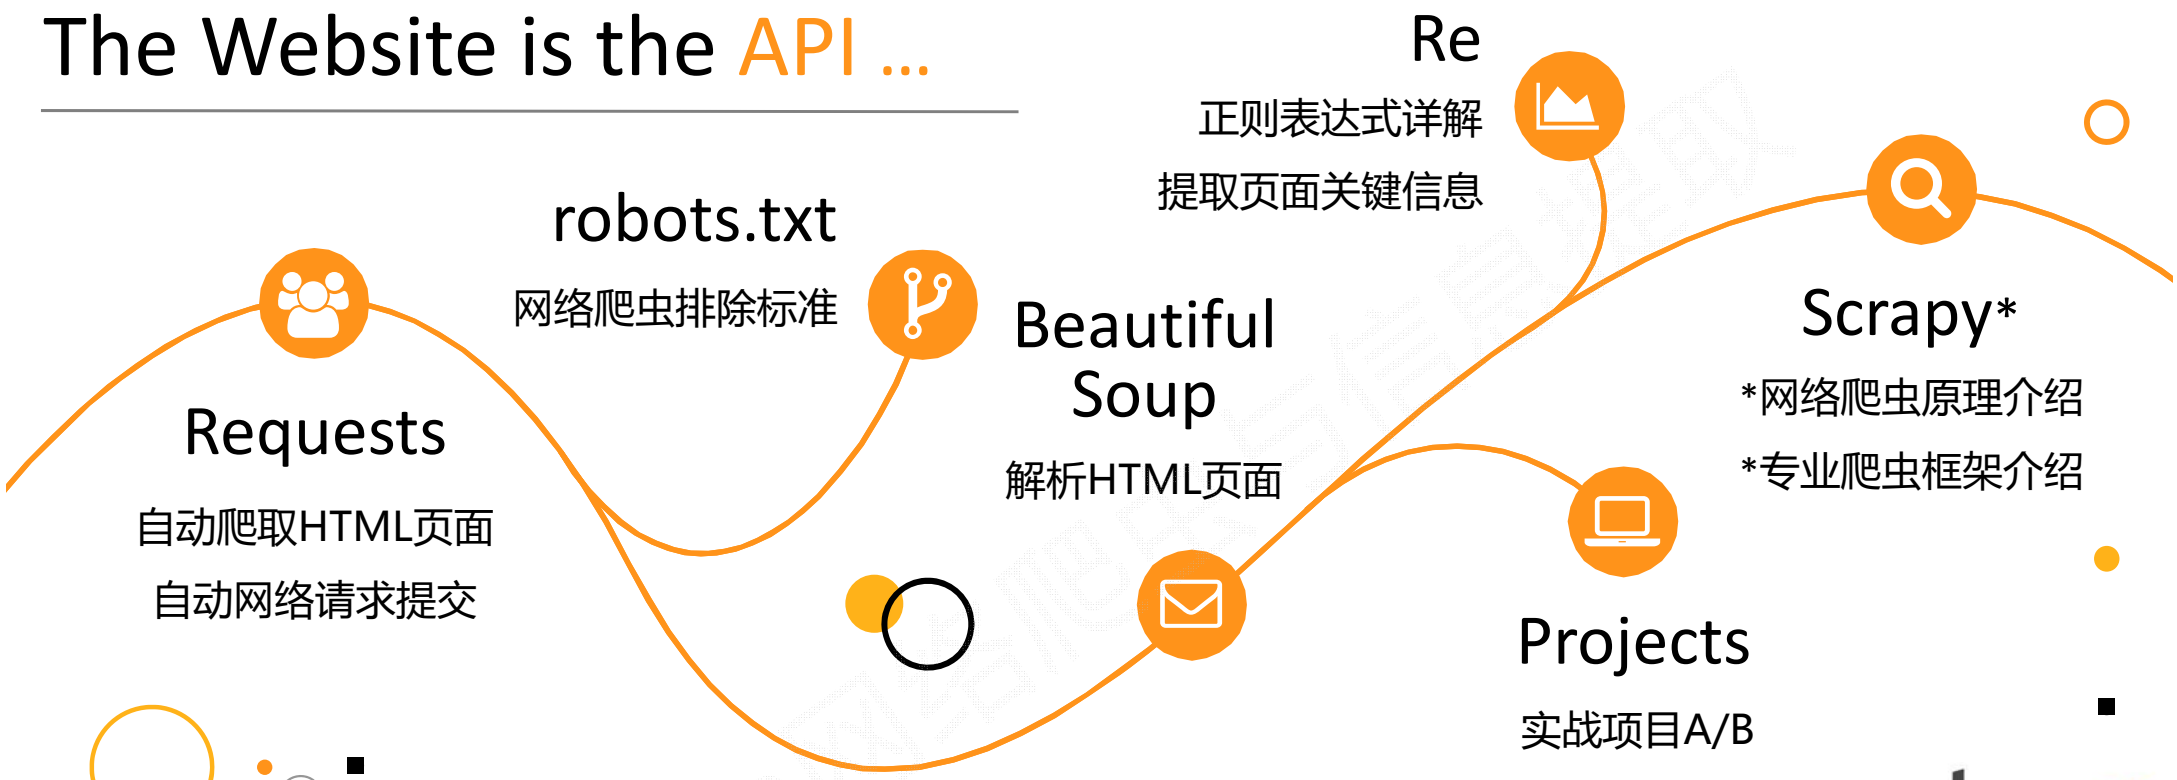

掌握定向网络数据爬取和网页解析的基本能力

python
弹指之间 · 享受创新

Python网络爬虫与信息提取

O4X -Tian

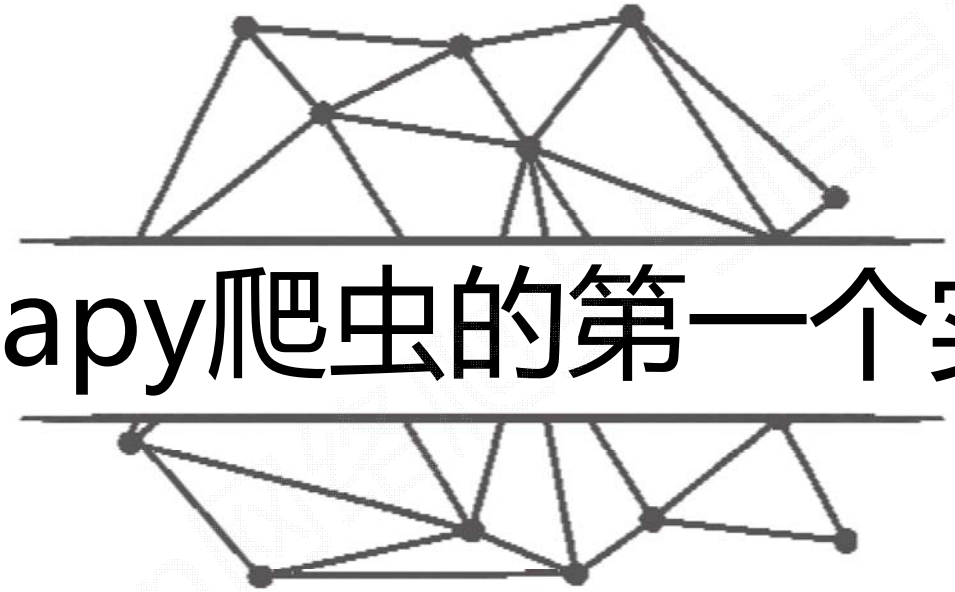

Scrapy爬虫的第一个实例

演示HTML地址

演示HTML页面地址：http://python123.io/ws/demo.html

文件名称：demo.html

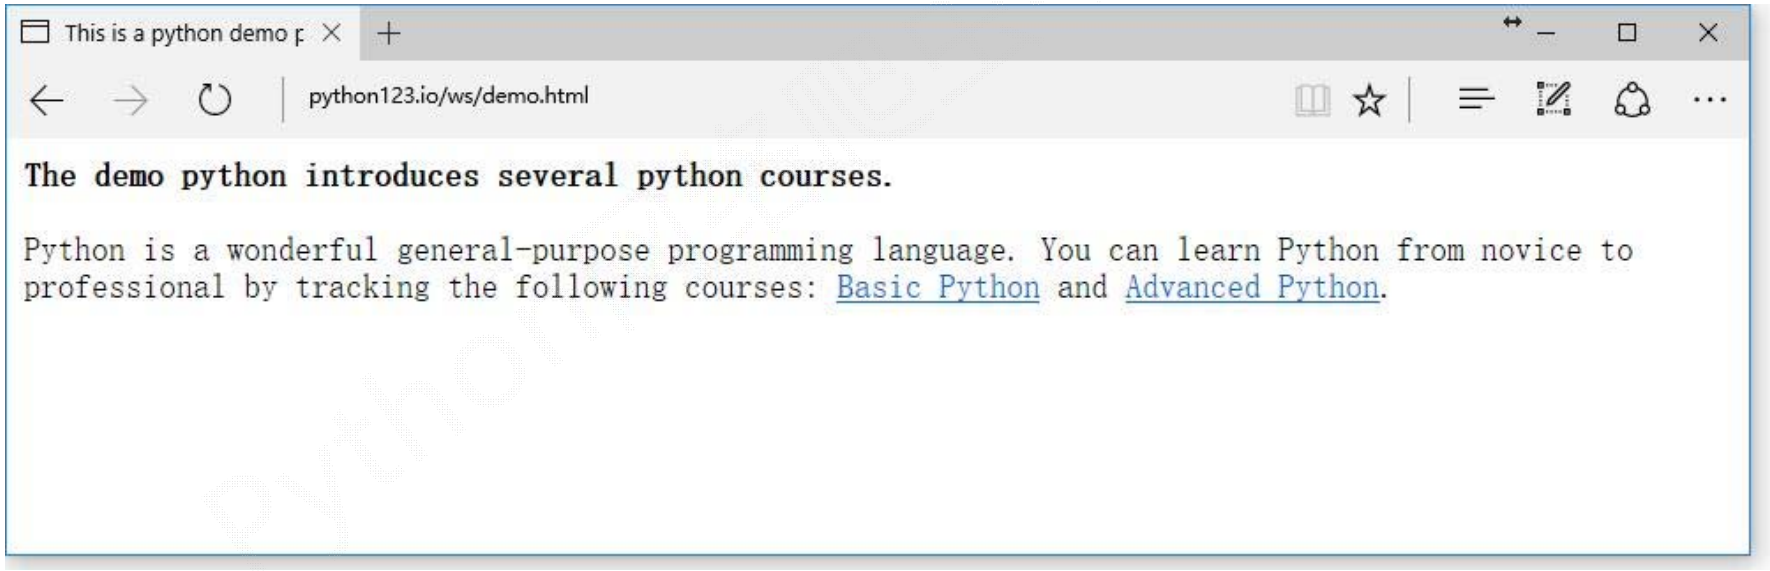

产生步骤（1）

应用Scrapy爬虫框架主要是编写配置型代码

步骤1：建立一个Scrapy爬虫工程

选取一个目录（D:\pycodes\），然后执行如下命令：

```
D:\pycodes>scrapy startproject python123demo
```

生成的工程目录

目录结构

python123demo/	外层目录
scrapy.cfg	部署Scrapy爬虫的配置文件
python123demo/	Scrapy框架的用户自定义Python代码
__init__.py	初始化脚本
items.py	Items代码模板（继承类）
middlewares.py	Middlewares代码模板（继承类）
pipelines.py	Pipelines代码模板（继承类）
settings.py	Scrapy爬虫的配置文件
spiders/	Spiders代码模板目录（继承类）
__pycache__/	缓存目录，无需修改

生成的工程目录

spiders/	⟶	Spiders代码模板目录（继承类）
__init__.py	⟶	初始文件，无需修改
__pycache__/	⟶	缓存目录，无需修改

内层目录结构　　用户自定义的spider代码增加在此处

产生步骤（2）

步骤2：在工程中产生一个Scrapy爬虫

进入工程目录（D:\pycodes\python123demo），然后执行如下命令：

```
D:\pycodes\python123demo>scrapy genspider demo python123.io
```

该命令作用：

(1) 生成一个名称为demo的spider

(2) 在spiders目录下增加代码文件demo.py

该命令仅用于生成demo.py，该文件也可以手工生成

demo.py文件

```
# -*- coding: utf-8 -*-
import scrapy

class DemoSpider(scrapy.Spider):
    name = "demo"
    allowed_domains = ["python123.io"]
    start_urls = ['http://python123.io/']

    def parse(self, response):
        pass
```

parse()用于处理响应，解析内容形成字典，

发现新的URL爬取请求

产生步骤（3）

步骤3：配置产生的spider爬虫

配置：（1）初始URL地址　（2）获取页面后的解析方式

```
# -*- coding: utf-8 -*-
import scrapy

class DemoSpider(scrapy.Spider):
    name = "demo"
#    allowed_domains = ["python123.io"] #可选
    start_urls = ['http://python123.io/ws/demo.html']

    def parse(self, response):
        fname = response.url.split('/')[-1]
        with open(fname, 'wb') as f:
            f.write(response.body)
        self.log('Saved file %s.' % fname)
```

产生步骤（4）

步骤4：运行爬虫，获取网页

在命令行下，执行如下命令：

```
D:\pycodes\python123demo>scrapy crawl demo
```

demo爬虫被执行，捕获页面存储在demo.html

回顾demo.py代码

```
import scrapy

class DemoSpider(scrapy.Spider):
    name = "demo"
    start_urls = ['http://python123.io/ws/demo.html']

    def parse(self, response):
        fname = response.url.split('/')[-1]
        with open(fname, 'wb') as f:
            f.write(response.body)
        self.log('Saved file %s.' % fname)
```

demo.py代码的完整版本

```
import scrapy

class DemoSpider(scrapy.Spider):
    name = "demo"

    def start_requests(self):
        urls = [
                  'http://python123.io/ws/demo.html'
                ]
        for url in urls:
            yield scrapy.Request(url=url, callback=self.parse)

    def parse(self, response):
        fname = response.url.split('/')[-1]
        with open(fname, 'wb') as f:
            f.write(response.body)
        self.log('Saved file %s.' % fname)
```

demo.py两个等价版本的区别

```
class DemoSpider(scrapy.Spider):
    name = "demo"
    start_urls = ['http://python123.io/ws/demo.html']
```

```
class DemoSpider(scrapy.Spider):
    name = "demo"

    def start_requests(self):
        urls = [
                'http://python123.io/ws/demo.html'
              ]
        for url in urls:
            yield scrapy.Request(url=url, callback=self.parse)
```

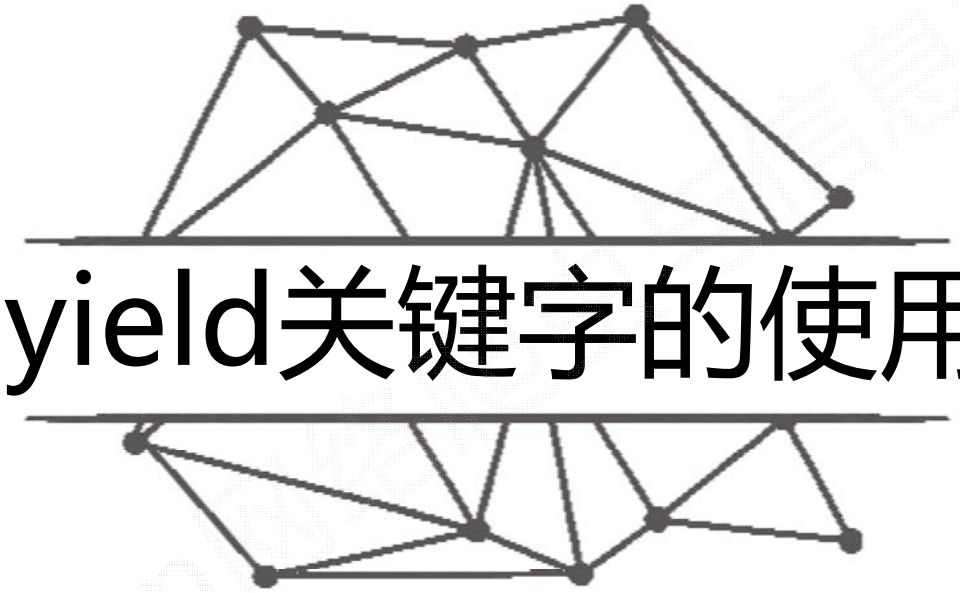

yield关键字的使用

yield关键字

yield ⟺ 生成器

包含yield语句的函数是一个生成器

生成器每次产生一个值（yield语句），函数被冻结，被唤醒后再产生一个值

生成器是一个不断产生值的函数

实例

```
>>> def gen(n):
        for i in range(n):
            yield i**2


>>> for i in gen(5):
        print(i, " ", end="")


0  1  4  9  16
>>>
```

生成器每调用一次在yield位置产生一个值，直到函数执行结束

为何要有生成器？

实例：求一组数的平方值

```
>>> def gen(n):
        for i in range(n):
            yield i**2


>>> for i in gen(5):
        print(i, " ", end="")


0  1  4  9  16
>>>
```

生成器写法

```
>>> def square(n):
        ls = [i**2 for i in range(n)]
        return ls

>>> for i in square(5):
        print(i, " ", end="")


0  1  4  9  16
>>>
```

普通写法

为何要有生成器？

生成器相比一次列出所有内容的优势：

1)更节省存储空间

2)响应更迅速

3)使用更灵活

```
>>> def square(n):
        ls = [i**2 for i in range(n)]
        return ls
```

```
>>> def gen(n):
        for i in range(n):
            yield i**2
```

如果n=1M、10M、100M或更大呢？

demo.py

```
import scrapy

class DemoSpider(scrapy.Spider):
    name = "demo"

    def start_requests(self):
        urls = [
                  'http://python123.io/ws/demo.html'
                ]
        for url in urls:
            yield scrapy.Request(url=url, callback=self.parse)

    def parse(self, response):
        fname = response.url.split('/')[-1]
        with open(fname, 'wb') as f:
            f.write(response.body)
        self.log('Saved file %s.' % fname)
```

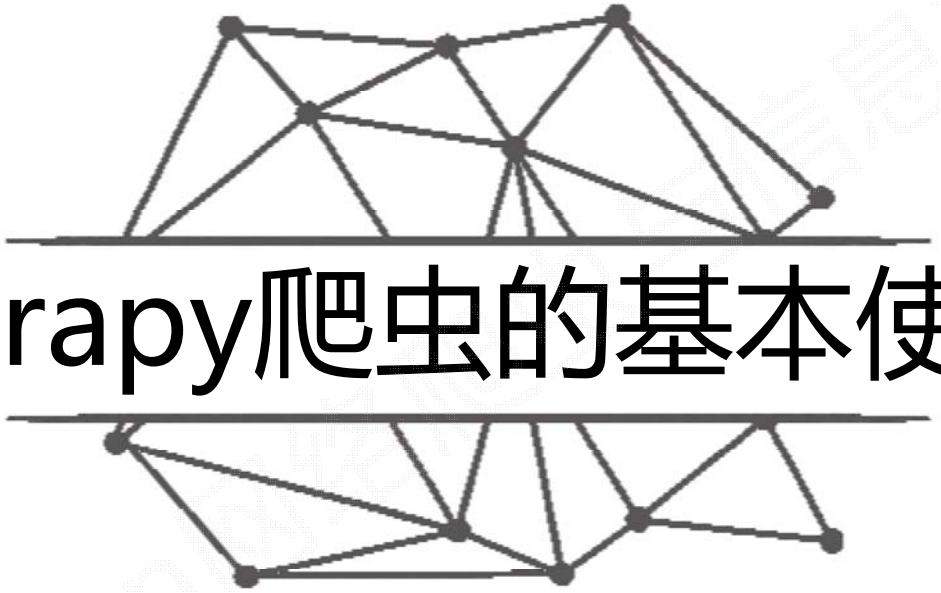

Scrapy爬虫的基本使用

Scrapy爬虫的使用步骤

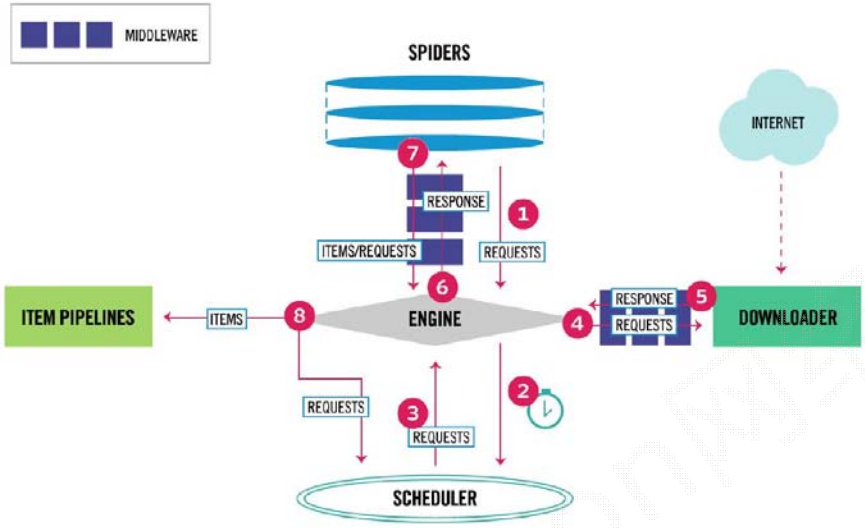

步骤1：创建一个工程和Spider模板

步骤2：编写Spider

步骤3：编写Item Pipeline

步骤4：优化配置策略

Scrapy爬虫的数据类型

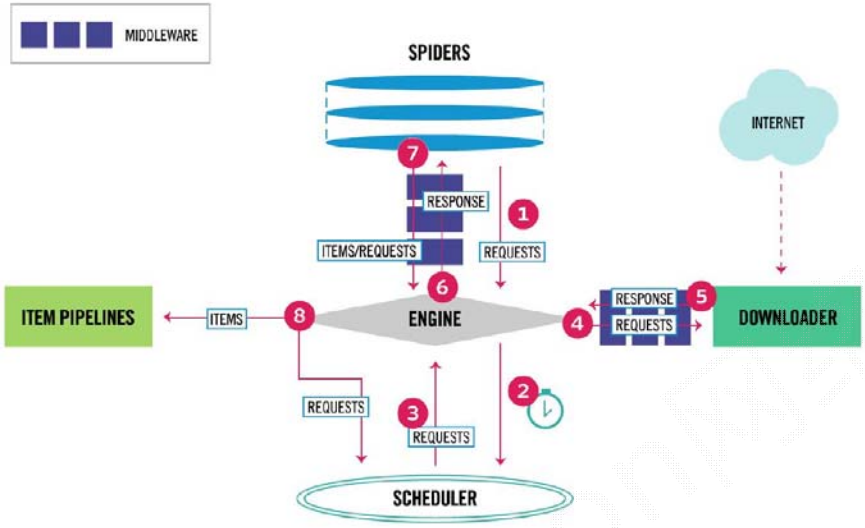

Request类

Response类

Item类

Request类

```
class scrapy.http.Request()
```

Request对象表示一个HTTP请求

由Spider生成，由Downloader执行

Request类

属性或方法	说明
.url	Request对应的请求URL地址
.method	对应的请求方法，'GET' 'POST'等
.headers	字典类型风格的请求头
.body	请求内容主体，字符串类型
.meta	用户添加的扩展信息，在Scrapy内部模块间传递信息使用
.copy()	复制该请求

Response类

```
class scrapy.http.Response()
```

Response对象表示一个HTTP响应

由Downloader生成，由Spider处理

Response类型

属性或方法	说明
.url	Response对应的URL地址
.status	HTTP状态码，默认是200
.headers	Response对应的头部信息
.body	Response对应的内容信息，字符串类型
.flags	一组标记
.request	产生Response类型对应的Request对象
.copy()	复制该响应

Item类

```
class scrapy.item.Item()
```

Item对象表示一个从HTML页面中提取的信息内容

由Spider生成，由Item Pipeline处理

Item类似字典类型，可以按照字典类型操作

Scrapy爬虫提取信息的方法

Scrapy爬虫支持多种HTML信息提取方法：

- Beautiful Soup
- lxml
- re
- XPath Selector
- CSS Selector

CSS Selector的基本使用

```
<HTML>.css('a::attr(href)').extract()
```

CSS Selector由W3C组织维护并规范

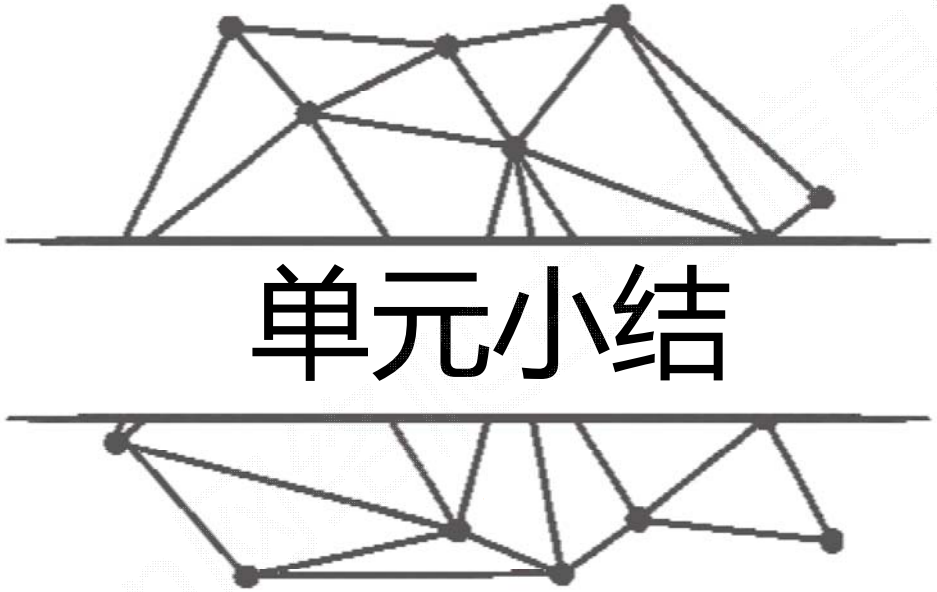

单元小结

Scrapy爬虫基本使用

Scrapy爬虫的第一个例子及目录结构

yield关键字和生成器

Request

Response

Item

CSS Selector的基本使用